

UNIVERSIDAD AUTÓNOMA DE NUEVO LEÓN
FACULTAD DE INGENIERÍA MECÁNICA Y ELÉCTRICA

Análisis de Datos en Minería de Datos: Relación entre las Emisiones de CO₂ y el Cambio de Temperatura Global

Proyecto Final

Materia: Tópicos Selectos de Ciencias de la Ingeniería 3

Profesor: M.A. Cesar Yael Santillán Marroquín

Alumna: Linda Caudana

Repositorio: github.com/LindaCaudana/co2-temperature-analysis

Ciudad Apodaca, Nuevo León — 2026

1. Introducción

El cambio climático es uno de los fenómenos más estudiados y documentados de las últimas décadas, y las emisiones de dióxido de carbono (CO₂) producto de la actividad humana se consideran uno de sus principales motores. El presente proyecto aplica técnicas de minería de datos —correlación, regresión lineal y clustering— sobre una base de datos pública e internacional con el fin de explorar, de forma cuantitativa, la relación entre las emisiones de CO₂ y el cambio de temperatura global atribuible a dichas emisiones.

El objetivo no es únicamente confirmar una relación ya conocida en la literatura científica, sino practicar el proceso completo de un proyecto de minería de datos: selección de una fuente confiable, limpieza y preparación de los datos, aplicación de técnicas analíticas, interpretación crítica de los resultados —incluyendo el reconocimiento de casos atípicos y limitaciones del análisis— y la comunicación clara de los hallazgos.

La pregunta que guía este trabajo es: *¿existe una relación medible entre las emisiones de CO₂ per cápita y totales de un país, y el cambio de temperatura que le es atribuible, considerando además el papel de variables como la población?*

2. Desarrollo

2.1 Selección de la Base de Datos

Se utilizó el conjunto de datos “CO₂ and Greenhouse Gas Emissions”, publicado y mantenido por **Our World in Data (OWID)**, en colaboración con el Global Carbon Project. Esta base es de acceso público, se actualiza regularmente y es ampliamente citada en investigación académica y periodismo de datos sobre cambio climático.

Fuente: <https://github.com/owid/co2-data>

2.2 Problemática a Resolver

Se planteó como problema determinar si existe una relación significativa entre las emisiones de CO₂ de un país y el cambio de temperatura global que le es atribuible, así como identificar el papel que juegan la población y el ingreso (PIB) en dicha relación.

Variable dependiente: cambio de temperatura atribuible al CO₂ (*temperature_change_from_co2*).

Variables independientes: emisiones totales de CO₂ (*co2*), emisiones de CO₂ per cápita (*co2_per_capita*) y población (*population*).

2.3 Descripción de los Datos

La base original contiene **50,411 registros y 79 columnas**, con una fila por país y año, cubriendo el periodo de **1750 a 2024** para **254 países y entidades** (incluyendo agregados regionales como

“World” o “Asia”). Entre las variables disponibles destacan emisiones de CO₂ por fuente (carbón, petróleo, gas, cemento), población, PIB, y el cambio de temperatura atribuible a distintos gases de efecto invernadero (CO₂, metano, óxido nitroso).

Variable	Descripción	Valores no nulos
country	País o entidad	50,411
year	Año de observación (1750–2024)	50,411
population	Población total	41,167
gdp	Producto Interno Bruto (USD internacional)	15,251
co2	Emisiones totales de CO ₂ (Mt)	29,384
co2_per_capita	Emisiones de CO ₂ por persona (t)	26,509
temperature_change_from_co2	Cambio de temperatura atribuible al CO ₂ (°C)	41,238

2.4 Preparación de los Datos

El proceso de limpieza se realizó en Python utilizando la librería **pandas**, siguiendo estos pasos:

- Se seleccionaron las columnas relevantes para el problema: país, año, CO₂, CO₂ per cápita, PIB, población y cambio de temperatura atribuible al CO₂ y a gases de efecto invernadero.
- Se eliminaron los registros correspondientes a agregados regionales (“World”, “Asia”, “European Union”, grupos de ingreso, etc.), ya que no representan países individuales y distorsionarían comparaciones entre entidades del mismo tipo.
- Se filtró el periodo a partir de 1950, dado que antes de esa fecha la cobertura de datos —especialmente de PIB y población— es muy escasa.
- Se eliminaron los registros con valores nulos en las variables clave del análisis (CO₂, CO₂ per cápita, cambio de temperatura y población), conservando intencionalmente las filas sin PIB para no perder observaciones útiles en los análisis que no requieren esa variable.

Etapas del filtrado	Registros resultantes
Base de datos original	50,411
Sin agregados regionales	46,836
Año ≥ 1950	18,009
Sin nulos en variables clave	15,218

El conjunto de datos final, denominado *df_clean*, quedó conformado por **15,218 registros** limpios, correspondientes a países reales en el periodo 1950–2024, sin valores nulos en las variables centrales del estudio.

2.5 Análisis de Datos

Se aplicaron tres técnicas de minería de datos: análisis de correlación, regresión lineal simple y clustering (K-Means). A continuación se describe cada una junto con sus resultados.

2.5.1 Análisis de Correlación

Se calculó la matriz de correlación de Pearson entre las variables CO₂ total, CO₂ per cápita, población y cambio de temperatura atribuible al CO₂.




Figura 1. Matriz de correlación entre las variables del estudio.

Relación	Coefficiente (r)	Interpretación
CO ₂ ↔ Cambio de temperatura	0.86	Correlación fuerte positiva
CO ₂ ↔ Población	0.66	Correlación moderada-fuerte
Población ↔ Cambio de temperatura	0.48	Correlación moderada
CO ₂ per cápita ↔ resto de variables	≈ 0.05	Correlación prácticamente nula

El coeficiente de correlación entre CO₂ total y cambio de temperatura fue de **r = 0.8595**, con un valor **p < 0.000001**, lo cual indica una correlación fuerte y estadísticamente significativa, considerando que se calculó sobre 15,218 observaciones.

Un hallazgo relevante es que el CO_2 per cápita prácticamente no correlaciona con ninguna otra variable. Esto sugiere que el impacto climático agregado de un país está más relacionado con su tamaño de población y su nivel de emisión total, que con la intensidad de emisión por persona.

2.5.2 Regresión Lineal

Se construyó un modelo de regresión lineal simple para predecir el cambio de temperatura atribuible al CO_2 a partir de las emisiones totales de CO_2 , utilizando la librería **scikit-learn**. Los datos se dividieron en 80% para entrenamiento (12,174 registros) y 20% para prueba (3,044 registros).




Figura 2. Relación entre emisiones de CO_2 y cambio de temperatura (todos los datos).




Figura 3. Ajuste del modelo de regresión lineal sobre el conjunto de prueba.

Métrica	Valor
Pendiente	0.0000232
Intercepto	0.00088
R ²	0.7245
RMSE	0.0073 °C

El modelo resultante es: **cambio de temperatura = 0.00088 + 0.0000232 × CO₂**. El coeficiente de determinación ($R^2 = 0.7245$) indica que el 72.45% de la variación en el cambio de temperatura se explica únicamente a partir de las emisiones de CO₂, lo cual constituye un ajuste considerablemente bueno para un modelo de una sola variable.

2.5.3 Análisis de Clusters (K-Means)

Se aplicó el algoritmo K-Means sobre las variables CO₂, CO₂ per cápita y población, previamente estandarizadas con *StandardScaler* para evitar que las variables de mayor escala dominen el agrupamiento. El número óptimo de clusters se determinó mediante el método del codo.




Figura 4. Método del codo: la inercia se estabiliza notablemente a partir de $k = 4$.

Con base en el método del codo se seleccionaron **4 clusters**, ya que a partir de ese valor la reducción de la inercia se vuelve marginal.




Figura 5. Distribución de los 4 clusters identificados.

Cluster	N	CO ₂ prom. (Mt)	CO ₂ /cápita prom.	Población prom.	Δ Temp. prom. (°C)	Perfil
---------	---	----------------------------	-------------------------------	-----------------	--------------------	--------

0	15,006	61.9	4.74	15.6 M	0.0023	Mayoría de países, bajo impacto
1	81	6,173.1	15.83	556.9 M	0.1575	Grandes emisores históricos
2	20	25.7	418.83	70.5 mil	0.00005	Casos atípicos (ver 2.6)
3	111	1,336.6	1.22	955.1 M	0.0263	Gigantes poblacionales, bajo per cápita

2.6 Interpretación de Resultados

Los tres análisis son consistentes entre sí: el coeficiente de correlación ($r = 0.86$) y el coeficiente de determinación de la regresión ($R^2 = 0.72 \approx 0.86^2$) coinciden matemáticamente, lo que confirma que los cálculos son correctos y que la relación lineal entre CO_2 y cambio de temperatura es robusta dentro de este conjunto de datos.

Es importante señalar que esta relación no debe interpretarse como un “descubrimiento” inesperado: la variable *temperature_change_from_co2* se calcula, en la metodología de Our World in Data, a partir de las emisiones acumuladas de CO_2 de cada país. Por ello, la fuerte correlación observada es, en buena medida, una consecuencia de cómo se construye el propio indicador, y no un hallazgo estadístico independiente. Esto se refleja visualmente en la Figura 2, donde cada “trayectoria” curva corresponde a un país distinto avanzando en el tiempo (1950–2024), conforme acumula emisiones.

El clustering reveló un grupo (Cluster 1) de grandes emisores históricos —encabezado por países como China y Estados Unidos— con el promedio más alto tanto de CO_2 total como de cambio de temperatura atribuible. En contraste, el Cluster 3 agrupa países muy poblados pero con bajas emisiones por persona, como es el caso de India, lo cual evidencia que el tamaño poblacional, más que la intensidad de emisión per cápita, explica buena parte del impacto climático agregado de un país.

El hallazgo más interesante del análisis fue el **Cluster 2**, compuesto por sólo 20 registros con un CO_2 per cápita extremadamente alto (promedio de 418.8 toneladas por persona). Al examinar estos casos a detalle se identificaron dos fenómenos distintos agrupados bajo la misma etiqueta estadística:

- **Territorios con población muy pequeña**, como Sint Maarten (parte holandesa) en la década de 1950–1970, con apenas 1,500 a 6,400 habitantes. En estos casos, el CO_2 per cápita se infla artificialmente porque la actividad económica total se divide entre una población mínima — es un artefacto estadístico, no un comportamiento real de alto consumo energético per cápita.
- **Un evento histórico extraordinario**: Kuwait en 1991, año en que ocurrieron los incendios petroleros provocados durante la Guerra del Golfo, tras la invasión de Irak. Cientos de pozos petroleros ardieron sin control durante meses, lo que disparó las emisiones de CO_2 del país a niveles atípicos para su población (364.8 t per cápita en ese único año).

Este hallazgo ilustra una limitación importante del clustering: el algoritmo agrupa por similitud numérica, sin distinguir si esa similitud responde a una causa estructural (un territorio pequeño) o a un evento puntual y extraordinario (una guerra). La interpretación de los resultados requiere, por tanto, contexto adicional que los datos por sí solos no proporcionan.

Como limitación adicional del modelo de regresión, se observa en la Figura 3 que el ajuste lineal describe bien la tendencia general, pero pierde precisión en los valores más altos de CO_2 (principalmente China, Estados Unidos e India), donde la relación parece tener cierta curvatura. Un modelo polinomial o de múltiples variables (incorporando PIB, por ejemplo) podría capturar mejor esta relación en investigaciones futuras.

3. Conclusiones y Recomendaciones

- Existe una relación fuerte y estadísticamente significativa entre las emisiones totales de CO₂ de un país y el cambio de temperatura global que le es atribuible ($r = 0.86$, $R^2 = 0.72$), aunque esta relación responde en parte a la forma en que se construye el propio indicador climático.
- El CO₂ per cápita, a diferencia del CO₂ total, no muestra correlación relevante con el cambio de temperatura ni con la población, lo que sugiere que el tamaño del país (en población y emisión total) pesa más que la eficiencia o intensidad de emisión por persona al evaluar el impacto climático agregado.
- El clustering permitió identificar perfiles claramente diferenciados de países —grandes emisores históricos, gigantes poblacionales de bajo per cápita y la mayoría de países de bajo impacto— así como casos atípicos cuya causa requirió investigación adicional (Sint Maarten y Kuwait 1991).
- Se recomienda, para trabajos futuros, incorporar el PIB como variable adicional en un modelo de regresión múltiple, así como explorar modelos no lineales que capturen mejor el comportamiento de los países con emisiones extremas.
- Finalmente, el proyecto evidencia la importancia de complementar los resultados estadísticos con investigación de contexto: un mismo patrón numérico (CO₂ per cápita alto) puede tener orígenes completamente distintos, y reconocerlo es parte esencial de un análisis de datos riguroso.

4. Referencias

Our World in Data. (2025). *CO2 and Greenhouse Gas Emissions* [Conjunto de datos]. Recuperado de <https://github.com/owid/co2-data>

Global Carbon Project. (2025). *Global Carbon Budget*. Recuperado de <https://globalcarbonbudget.org/>

Friedlingstein, P. et al. (2025). *Global Carbon Budget 2025*. Earth System Science Data.

Jones, M. W. et al. (2025). *National Contributions to Climate Change Due to Historical Emissions of Carbon Dioxide, Methane and Nitrous Oxide*. Scientific Data.

Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825-2830.

The pandas development team. (2024). *pandas-dev/pandas: Pandas* [Software]. Zenodo.